

Sentinel-30

보이스피싱 산업의 ROI를 무너뜨리는
AI 능동방어 플랫폼

"우리는 피해자를 지키지 않는다. 사기범을 망친다."

30분

환수 골든타임

₩1.97조

2024 보이스피싱 피해

7

Defense-in-Depth 레이어

MECHANISM

사기범 발신 → 미끼봇 흡수 → 정보 추출 → FDS·통신사·경찰망 자동 공급 → ROI 붕괴

CATEGORY

AI 기반 보이스피싱 공동 대응

DATE

2026-05-12

TEAM

6인 (기획 1 / ML 2 / 백엔드 1 / UX 1 / 법리·보안 1)

STAGE

예선 4주 + 본선 무박 2일

기획 개요

프로젝트 개요와 핵심 정의

1.1 한 줄 정의

사기 산업의 시간당 매출을 0으로 만드는 AI 능동방어 플랫폼. 영국 O2 Daisy AI(2024) 사례를 한국의 금융 워크플로우와 6개 법령 합법성 검토 위에 재설계했다.

1.2 프로젝트 정보

항목	내용
프로젝트명	Sentinel-30
주제 카테고리	(8) AI 기반 보이스피싱 공동 대응
팀 구성	6인 (기획 1 / ML 2 / 백엔드 1 / UX 1 / 법리·보안 1)
진행 단계	예선 4주 + 본선 무박 2일

1.3 기존 솔루션의 한계

- 통신사·핀테크·공공 솔루션 모두 "방어"에만 집중 — 사기범이 치를 비용은 사실상 0
- 그 결과 사기범 입장에서 잃을 자원이 없으므로 사기 산업은 멈추지 않는다
- Sentinel-30은 사기범의 시간·정보·도구라는 자원을 약탈하는 Active Defense 모델로 재정의한다

환경분석

외부 환경과 시장의 압력

2.1 시장 압력 — 외부 요인 4종

영역	동향	시사점
정책	금감원 「전자금융감독규정」 §31~38 침해사고 대응 강화 (2024 개정)	IR 워크플로우 24시간 자동 신고로 규제 부합
법제	AI 기본법 2024 제정·2026 시행, 인간 사칭 고지 의무	계도기간(2027.1까지) 시범 운영 + 예외 고지 제정 건의
기술	한국어 LLM 고도화 (HyperCLOVA X, EXAONE 3.5), TTS 자연도 향상	노인 페르소나 봇 실현 가능성 확보
국제	영국 Ofcom Voice Scam Action Plan(2024), Daisy AI 적법성 인증	한국형 적법성 모델 벤치마크 가능

2.2 시장 데이터 — 사회적 압박 최고치


지표	수치	출처
국내 보이스피싱 피해액	8,545억 원	경찰청 2024 (전년 대비 1.9배↑)
발생 건수	약 21,000건	경찰청 2024
60대 이상 피해 비중	52.3%	경찰청 2024
1건당 평균 피해액	약 4,100만 원	경찰청 2024 (총액÷건수 환산)
피해 환수율	25% 미만	금융감독원 2024
글로벌 사기방지 시장 CAGR	22.8% (2024~2030)	MarketsandMarkets 2024

주제 및 아이디어 도출

3C · SWOT · 페르소나로 본 차별화


3.1 문제 재정의 — 사기 산업 ROI 파괴

기존 정의 "어떻게 통화를 막을 것인가" → 본 프로젝트는 "어떻게 사기 산업의 시간당 수익률을 0으로 만들 것인가" 로 재정의한다.



3.2 30분 골든타임 — 시간을 자산화

송금 완료(T+15) ~ 인출 시작(T+30) 사이의 15분이 환수 가능한 골든타임이다. Sentinel-30은 이 구간에 미끼봇 시간 약탈, 정보 허브 수집, 통신사 번호 차단, 경찰망 자동 신고를 병렬로 작동시킨다.



3.3 3C 분석

구분	분석
Company (자사)	6인 학생팀, 풀스택 구현 한계 있으나 법리·보안 트랙 1명 전담 — 다른 팀에 없는 차별화 자원
Customer (고객)	1차: 시중은행 디지털보안 부서, 금감원 / 2차: 60대 이상 고령 사용자 + 자녀
Competitor (경쟁)	통신사 필터·시티즌코난·토스 사기의심사이렌·SKT 에이닷 모두 탐지·차단 중심 — 능동 약탈 영역은 비어 있음

3.4 SWOT 분석



3.5 경쟁사 기능 비교


기능 / 항목	Sentinel-30 (자사)	KT 후후	SKT 에이닷	토스 사이렌	시티즌코난	더치트
사기범 번호 블랙리스트	○	◎	○	○	×	◎
통화 실시간 STT 분석	○	○	◎	×	×	×
사기 시나리오 자동 분류	◎ (8종+LLM)	○ (SLM)	○ (SLM)	×	×	×
악성앱 탐지	×	×	×	×	◎	×

기능 / 항목	Sentinel-30 (자사)	KT 후후	SKT 에이닷	토스 사이렌	시티즌코난	더치트
사기범 시간 약탈 (미끼봇)	◎	×	×	×	×	×
사기범 음성지문 DB	◎	×	×	×	×	×
멀티 에이전트 LLM 구조	◎	×	×	×	×	×
금감원 24시간 자동 신고	◎	×	×	×	×	×
가족 알림 + 송금 거부권	◎ (송금 차단)	×	○ (가족 케어, 알림만)	×	×	×
6개 법령 합법성 검토서	◎	×	×	×	×	×
MITRE ATLAS 위협 모델	◎	×	×	×	×	×

범례: ◎ 핵심 차별화 / ○ 지원 / △ 부분 지원 / × 미지원

→ 경쟁사가 모두 "탐지·차단" 수동 방어에 머무는 동안, Sentinel-30은 유일하게 사기범
자원(시간·음성·계좌)을 능동 약탈하여 사기 산업 ROI 자체를 무너뜨린다.

3.6 핵심 페르소나




콘텐츠 및 서비스 기획

7대 레이어와 시스템 아키텍처

4.1 7대 레이어 — Defense-in-Depth




4.2 시스템 아키텍처



4.3 차별화 핵심 — 멀티 에이전트 LLM (컨텍스트 윈도우 해결)

기존 챗봇은 단일 LLM으로 통화를 처리하여, 30분~2시간 길이의 통화에서는 컨텍스트 200K 토큰이 소진되며 응답 지연·환각·페르소나 붕괴가 발생한다. Sentinel-30은 역할별 5종 에이전트로 분리해 이 문제를 구조적으로 해결한다.




핵심: Memory Compactor가 5턴마다 요약하여 Orchestrator(Opus)에는 항상 [요약본 + 최근 2턴]만 주입한다. 통화 길이와 무관하게 입력 토큰이 일정해 응답 지연 1.5초 이하를 유지하며, Sonnet/Haiku 티어링으로 토큰 비용도 -62%.

Memory Compactor 동작 (Haiku, 평균 1.4초)

1. 트리거: 대화 턴 수가 5의 배수에 도달하거나 누적 입력 토큰이 6K 초과
2. 요약 프롬프트: 직전 5턴을 입력으로 받아 (a) 사기범 발화 핵심 주장, (b) 추출 엔티티(계좌·URL·인물), (c) 시나리오 분류 신뢰도, (d) 다음 응대 권장 톤 — 4개 필드를 JSON으로 출력
3. 버퍼 갱신: 기존 요약본 + 신규 요약본을 한 번 더 압축(LRU 방식, 최대 8K 토큰 유지), 직전 2턴 원문은 그대로 보존
4. Orchestrator 입력: $[\text{summary}_n] + [\text{turn}_{n-1}] + [\text{turn}_n]$ — 통화 길이와 무관하게 항상 ≤ 8K 토큰 보장
5. 안전장치: 요약 실패 시 직전 요약본 재사용 + Safety Guard 알람, 5턴 원문은 별도 archive에 보관(수사 증거 보존)

4.4 차별화 핵심 — 예외 시나리오 Fallback + Active Learning

8종 사기 시나리오 분류기의 신뢰도(confidence)가 0.6 미만이면 "Unknown_Scam"으로 분기해 일반 노인 페르소나로 통화를 유지하면서 정보는 계속 수집한다. 주간 배치로 Unknown 통화를 클러스터링·라벨링해 새 시나리오로 등재하는 Active Learning 루프가 분류 정확도를 매주 자동 개선한다.



4.5 핵심 기능 상세

(1) AI 미끼봇 (Honeybot Bot)

- 목적: 사기범 시간 약탈 + 자발적 정보 노출 유도
- 기술: 멀티 에이전트 LLM (Opus 1 · Sonnet 3 · Haiku 1) + 한국어 STT + 노년 TTS
- 가드레일: 욕설·협박·인격모독 금지 / 실존 제3자 정보 사용 금지 (Safety Guard가 사전 검열)
- 목표 KPI: 평균 통화 유지 30분 이상, 정보 추출률 60% 이상

(2) 사기범 정보 수집 엔진

- Speaker Embedding 기반 사기범 음성지문 DB (Qdrant)
- 사기 시나리오 8종 분류 + Unknown fallback (검찰·은행·자녀·택배·대출·세무서·경찰·보안업체)
- 계좌·URL·악성앱 패키지명 정규표현식 + LLM 보조 추출 (Info Extractor 에이전트)

(3) 실시간 정보전 허브

- REST API 게이트웨이 (통신사 번호 차단, 경찰청 사이버수사대, 금감원 24시간 자동 신고)
- FDS 즉시 동결 연계는 v2 로드맵 (시중은행 PoC 사업화 후 진행)
- IR 워크플로우: 탐지 → SIEM 알람 → CERT 1차 분석(5분) → CISO 보고(10분) → 금감원 24시간 자동 충족

(4) AI 자체 보안 계층 — MITRE ATLAS · OWASP LLM Top 10

- AML.T0043 적대적 음성 샘플 → 적대적 학습으로 방어
- AML.T0048 모델 입력 조작 → 입력 정규화·임계값 동적 조정
- LLM01 Prompt Injection → 입출력 검증 / LLM06 PII Disclosure → 마스킹


(5) 시니어 가디언 UX

70대 5명 인터뷰 기반, 24pt 이상 큰 글씨 + 음성 경고 + 자녀 동반 알림 + 1억 원 이상 송금 시 5분 내 자녀 거부권

4.6 MoSCoW 우선순위

우선순위	항목
Must have	멀티에이전트 미끼봇, 사기 시나리오 8종 분류기 + Unknown fallback, 음성지문 DB, 30초 시연 영상, 법적 안전지대 설계서
Should have	MITRE ATLAS 위협 모델 라이브 시연, 시니어 가디언 앱 프로토타입, Active Learning 루프 v1
Could have	다국어 사기범 응대(중국어·러시아어), 통신사·은행 실 API 연계, AML 자금세탁 영역 확장
Won't have (이번)	FDS 실연계, 사기범 시스템 침입(역공격·Hack-Back), 사기범 실시간 위치 추적, 국제 공조 데이터 공유

4.7 구현 범위 — 실구현 vs v2 로드맵



운영 전략

타겟 · 예산 · 일정 · 역할


5.1 타겟별 전략

타겟	전략
시중은행 디지털보안 부서	사기범 계좌·시나리오 실시간 피드 → FDS 를 자동 갱신 PoC
금감원·금융보안원	침해사고 24시간 자동 신고 + 규제 샌드박스 제안
통신사	미끼번호 풀 공급 협력 (KT·SKT 정식 MoU 체결)
고령 사용자 + 자녀	시니어 가디언 앱 — 가족 동반 알림 + 송금 거부권

5.2 예산 (예산 4주 기준)

항목	합계
Claude API · GPT-4o · HyperCLOVA X 호출	400,000원
Naver ClovaVoice / ElevenLabs TTS	150,000원
70대 사용성 인터뷰 사례비 (5명)	250,000원
시연 영상 편집 외주	200,000원
클라우드 인프라 (AWS / Naver Cloud)	200,000원
기타 (디자인 라이선스·소품)	100,000원
합계	약 130만 원

5.3 일정 — 간트차트



5.4 팀 EFFORT 배분

역할	인원	EFFORT	주요 산출물
기획·발표 리더	1	15%	기획서 / 발표자료 / 메시지
ML / 봇 개발	2	35%	멀티에이전트 봇 + STT/TTS + 시나리오 분류기
백엔드 / 통합	1	15%	API 게이트웨이 + Kafka 이벤트 허브 + DB
UX / 시연 영상	1	15%	시니어 가디언 앱 + 시연 영상 + 인터뷰
법리·보안 트랙	1	20%	법적 안전지대 + IR 플레이북 + MITRE ATLAS + OWASP LLM

5.5 본선 시연 구성 — 3분할 동시 가시화


라이브 시연은 사기범 목소리 녹음 파일을 입력으로 사용하고, 화면을 3분할해 무엇이 실시간으로 일어나는지 동시에 보여준다. 정상 케이스(검찰사칭) 1건 + 예외 케이스(Unknown fallback) 1건을 시연하며, 네트워크/API 장애 대비 백업 녹화 영상도 별도 준비한다.

Live Demo Layout

본선 라이브 시연 화면 — 3분할 동시 가시화

LEFT · 사기범 입력 음성

(녹음 파일 재생)



검찰입니다.
김지수 씨 통장이...
(시연용 더미 대본)

▶ 00:42 / 02:15

CENTER · 멀티 에이전트 동작

(처리 중인 에이전트가 발광)

Orchestrator
[Opus] 분기 결정 중

Persona
[Sonnet] 응답 생성

Memory
[Sonnet] T+38 압축 완료

Extractor
[Sonnet] 계좌 추출 시도

Safety
[Haiku] OK

RIGHT · 실시간 추출 결과


(허브로 전송되는 데이터)

시나리오	검찰 사칭	98%
음성지문	VP-3a8f...	신규
계좌	농협 301-XX	검출
URL	—	
악성앱	—	
발신번호	+82-10-XXXX	변조 의심
통화시간	00:42 → 진행	

사기범 음성 → 멀티에이전트 동작 → 추출 결과 동시 가시화

KPI 대시보드

성과를 측정하는 4대 지표




KPI	목표치	측정 주기	측정 방법	미달 시 대응
사기 통화 탐지율	85% 이상	일간	라벨링 데이터셋 vs 분류기 결과	분류기 추가 학습 / 시나리오 데이터 확장
사기범 시간 약탈 (분/통화)	평균 30분 이상	주간	미끼봇 통화 로그 평균	페르소나 응대 시나리오 다양화
사기범 정보 추출률 (2개+ 확보)	60% 이상	주간	추출 파이프라인 로그	정규표현식·LLM 보조 튜닝
환수 골든타임 (분)	30분 이내 동결 트리거	건별	허브 API 호출 → FDS 응답 시각	API 폴링 주기 단축, 큐 우선순위 조정
법정 신고시한 (24시간) 충족률	100%	월간	IR 워크플로우 로그	자동 신고 트리거 검증 / 알람 이중화
시니어 가디언 알림 도달률	95% 이상	주간	앱 푸시 수신 ACK	푸시 채널 이중화 (FCM+SMS)

KPI	목표치	측정 주기	측정 방법	미달 시 대응
70대 사용성 만족도	4.0/5.0 이상	분기	사용성 인터뷰 + 설문	UX 개선 스프린트
Unknown_Scam → 신 시나리오 등재	분기 1건 이상	분기	Active Learning 배치 로그	클러스터링 임계값·라벨링 SLA 조정

SMART 검증: 모든 KPI는 Specific · Measurable · Achievable · Relevant · Time-bound 충족.

리스크 매트릭스

발생확률 × 영향도



#	리스크	위험등급	대응 방안
R1	미끼봇 협박·모욕·인격모독 발화	매우높음	페르소나 LLM 가드레일 + Safety Guard 사전 검열 레이어 + 인간 검토자 샘플링
R2	실존 제3자 정보 노출 (실제 계좌·주소)	높음	모든 정보 임의 생성 — 실존 자원 불사용 원칙
R3	사기범 데이터 무기한 보관	보통	수집 → 수사기관 제공 → 90일 내 파기 정책
R4	사기범 음성지문 오인식 (선의의 일반인)	높음	보수적 임계값 + 인간 검토자 최종 확인 + 이의신청 절차

#	리스크	위험등급	대응 방안
R5	통신사 약관·전기통신사업법 위반	높음	KT·SKT 정식 MoU 협력 + 법무 사전 자문
R6	AI 인간 사칭 윤리 (AI 기본법)	높음	계도기간 활용 + 예외 고시 제정 건의 + 통화 종료 후 수사기관 자동 고지
R7	적대적 공격으로 모델 분류 우회	보통	적대적 학습 + 임계값 동적 조정 + 다중 모델 양상블
R8	사용자 개인정보 유출 (가디언 앱)	보통	AES-256 + 가명처리 + ISMS-P 통제항목 적용

법적 안전지대 설계

6개 법령과 6대 리스크 방어

8.1 본 솔루션의 법적 분류 — Deceptive Defense

카테고리	한국 법적 지위
Passive Defense (방화벽·탐지)	○ 합법
Deceptive Defense (기만·허니팟)	○ 합법 — 본 프로젝트 영역
Active Reconnaissance	△ 회색
역공격·Hack-Back	× 불법

우리는 사기범 시스템에 침입하지 않는다. 사기범이 우리 미끼번호로 전화를 걸어와 자기 정보를 자발적으로 흘리는 것을 수집한다.


8.2 한국 6대 법령 합법성 검토

법령	조문	적용 결과
통신비밀보호법	§3 (감청 정의) · §14 (대화 비밀)	○ 통화 당사자 일방 녹음은 §3의 '감청'에 해당하지 않음 — 미끼봇이 통화 당사자이므로 녹음 합법 (대법원 2008. 10. 23. 선고 2008도1237)
개인정보보호법	§15 (1) 4호 (급박한 재산상 이익 보호)	○ 잠재 피해자 보호 근거
개인정보보호법	§15 (1) 6호 (정당이익)	○ 사기 차단 목적의 정당이익
개인정보보호법	§18 (2) 7호 (범죄수사 시 제3자 제공)	○ 경찰·금감원 제공 합법
신용정보법	§32 (2) 4호 / §32의2 (가명정보)	○ 범죄수사 시 신용정보 제공, 은행 간 사기 패턴 공유

법령	조문	적용 결과
정보통신망법	§48 (해킹 금지)	○ 우리는 침입 안 함 — 무관
형법	§20 (정당행위)	○ 사기 차단 목적의 기만은 사회상규에 부합
AI 기본법 (2026.1.22 시행)	생성형 AI 결과물 표시 · 인간 사칭 금지	△ 시행령에 공공안전 예외 없음. (1) 계도기간(2027.1.21까지) 시범 운영 (2) 형법 §20·전기통신금융사기 특별법 §15 근거로 과기정통부에 예외 고시 건의 (3) 통화 종료 직후 수사기관에 AI 사용 사실 자동 고지

8.3 데이터 수집 경로 분리 — 미끼봇 vs 가디언 앱

미끼봇 측 수집은 통화 당사자가 사기범이므로 별도 동의가 필요 없으나, 시니어 가디언 앱 사용자의 통화 메타데이터는 명시적 동의를 요구한다. 두 경로를 분리해 합법성을 명확히 한다.



8.4 글로벌 사례 비교

사례	법적 근거	본 프로젝트 대응
영국 O2 Daisy AI (2024)	UK GDPR + Investigatory Powers Act 2016	한국 개인정보보호법 §15 (1) 4·6호 + §18 (2) 7호
영국 Ofcom 적법성 인증	통신청 가이드	방통위·금감원 사전 협의 (제언)

8.5 면접·심사위원회에게 박히는 한 줄

"Active Defense는 윤리·법적 회색지대로 자주 오해받습니다. 우리는 한국 개인정보보호법 §15 (1) 6호, §18 (2) 7호, 통신비밀보호법 §14, 형법 §20 정당행위 조항을 근거로 합법 영역에서 작동하도록 설계했습니다. 사기범을 망치되, 법을 어기지 않습니다."

기대 효과 및 사회 공헌

사기 산업 ROI를 0으로

9.1 사회적 효과 추정 (보수적)

지표	현재 (2024)	Sentinel-30 도입 1년차	산정 근거
보이스피싱 피해액	8,545억 원	-15% (약 1,280억 원 절감)	미끼봇 시간 약탈 + 정보 허브 즉시 동결
60대 이상 피해 비중	52.3%	-40% (시니어 가디언 효과)	가족 동반 알림 + 송금 거부권
환수 골든타임	240분	30분	허브 API 자동 동결 트리거
사기범 시간당 매출	(산정 불가)	0에 수렴	미끼봇이 사기범 시간을 30분~2시간 약탈

9.2 차별화 산출물 — 기존 솔루션 대비 핵심 차이

- 법적 안전지대 설계서 — 6개 법령 합법성 검토 (시중은행·금감원 즉시 활용 가능)
- MITRE ATLAS / OWASP LLM Top 10 위협 모델 — AI 보안 실무 적용
- 멀티 에이전트 LLM 구조 — 통화 2시간 이상에도 컨텍스트 한계 없는 봇 (단일 LLM 기반 솔루션 대비 구조적 우위)
- Active Learning 루프 — 신규 사기 시나리오 자동 등재 (분류 정확도 매주 자동 개선)
- 시니어 가디언 UX — 70대 5명 정성 인터뷰 근거

9.3 향후 발전 방향

- v2 (3~6개월) — 시중은행 FDS 실연계 PoC, 통신사 미끼번호 폴 정식 협력, 경찰청 사이버수사대 정식 채널
- v3 (6~12개월) — 다국어 사기범 응대 (중국어·러시아어), 글로벌 거점 정보 공유, AML 자금세탁 영역 확장
- v4 (1년+) — 동남아·일본 등 한국형 모델 수출 (Ofcom Daisy AI 역방향 벤치마크)

참고문헌

근거 자료와 인용

10.1 법령 (모두 현행)

- 통신비밀보호법 §14 (대화 비밀 보호)
- 개인정보보호법 §15 (1) 4·6호, §18 (2) 7호
- 신용정보법 §32 (2) 4호, §32의2 (가명정보)
- 정보통신망법 §48 (해킹 금지)
- 형법 §20 (정당행위)
- AI 기본법 (2024 제정, 2026 시행)
- 금감원 「전자금융감독규정」 §31~38 (2024 개정)

10.2 가이드 · 표준

- MITRE ATLAS — Adversarial Threat Landscape for AI Systems
- OWASP LLM Top 10 (2024)
- 금융보안원 「침해사고 대응 가이드」
- ISMS-P 인증 통제항목

10.3 통계 · 시장 자료

- 경찰청 보이스피싱 피해 통계 (2024)
- 금융감독원 환수율 발표 (2024)
- MarketsandMarkets — Global Fraud Detection & Prevention Market (2024)
- 한국금융보안원 FDS 시장 보고서 (2024)
- KISDI AI 금융보안 시장 전망 (2024)

10.4 글로벌 사례

- 영국 O2 Daisy AI (2024) — Active Defense 첫 상용 사례
- 영국 Ofcom Voice Scam Action Plan (2024)
- 대법원 2008도1237 — 통화 당사자 녹음 합법 판례