

Sentinel-30

보이스피싱 능동방어 인공지능(AI) 플랫폼 — 30분 환수 골든타임 자동화

탐지·차단을 보완하여 사기범의 시간·음성·계좌 정보를 증거 자산으로 수집하는 시스템.

RESEARCH QUESTION

사기 산업의 시간당 수익률을
어떻게 0에 가깝게 만들 것인가?

Golden Time · Guardian Live · Multi-Agent LLM

30분

환수 골든타임
송금완료~인출시작

8,545억

2024 피해액
경찰청, 전년 1.9배 증가

52.3%

60대 이상 피해
고령층 집중

7

Defense-in-Depth
능동방어 7대 레이어

발표 구성

8개 챕터로 평가 4항목(문제 적합성·AI 활용·파급력·혁신성)에 증거를 매핑하여 배치

01

프로젝트 개요

한 줄 정의 · 팀 · 일정

02

문제 정의 및 필요성

보이스피싱 8,545억 · 환수 25%

03

핵심 아이디어

ROI 재정의 · 서비스 흐름 · AI 활용

04

구현 범위 및 개발 현황

4주 실구현 · 운영비 · 일정

05

데모 시나리오

페르소나 · 와이어프레임 · 본선 시연

06

법적 안전장치

6법령 검토 · 데이터 거버넌스

07

KPI 및 효과 측정

SMART 4종 · 리스크 매트릭스

08

확장성 및 기대효과


사회적 효과 · 로드맵 · 사업화

→ 정확한 정보·보수적 추정·자체 검토 기반 — 과장된 주장은 모두 단서 조항으로 보완.

보이스피싱 피해 현황 — 왜 지금인가


비대면 거래 확산 + AI 사기 자동화 + 환급법 한계(-22~35%) — 능동적 보완책이 필요한 시점

연도별 보이스피싱 피해액 (억 원)



출처: 경찰청 — 2024년 8,545억으로 역대 최고

유형별 피해 비중 (2024)



1인당 피해 +73% (평균 4,100만원) · 발생 건수 -33% (2021 대비) · 환수율 25% 미만

➔ 사기범 입장에서 앓을 자원이 없는 구조 — 방어를 보완할 능동 자산 회수 모델이 필요하다.

전체·타겟·도달 시장 분해 (보수적 추정)

전체 시장(TAM)·타겟 시장(SAM)·도달 가능 시장(SOM)은 "피해 보호 가능 시장" 기준 — 운영 수익은 정부 R&D·조달 별도 트랙

TAM 전체 피해 보호 시장

연 8,545억 원

정의

한국 보이스피싱 연 총 피해액

출처

경찰청 2024 통계 (전년 1.9배↑)

의미

솔루션이 100% 보급 시 보호 가능 상한

매출 X

이 자체는 우리 매출 아님

SAM 타겟 피해 보호 시장

연 4,471억 원

정의

60대 이상 피해 (52.3%)

핵심

기관사칭형 75% 중복 영역

의미

시니어 + 기관사칭 = 우리 타겟

매출 X

보호 가능 시장 — 운영 수익 별개

SOM 1차 5년 보호 도달량

연 33~66억 (5년 누적 165~330억)

계산

65+ 스마트폰 665만 × 보급 1~5%

=

33만 명 × 연 5건 × 피해율 0.5%

운영 수익

B2G R&D·조달 매출은 별도

실현 조건


정부 협력 성사 시 상한

→ SOM은 "피해 보호 가능 시장" — 운영 매출은 정부 R&D·조달 별도 트랙으로 추진 (Slide 29 참조).

보이스피싱 대응 시장 지도

B2C × 통화 시점 = 통신사 미가입자(어르신·자녀 보호자)가 통화 도중 보호받을 수 없는 영역 — 우리가 이 자리에 진입

보이스피싱 대응 시장 포지셔닝 — 비어있는 'B2C × 통화 시점' 영역



➔ 정부 통합대응단·ASAP·통신사 4사가 채운 영역 분석 — 비어있는 'B2C × 통화 시점' 영역에 진입.

기존 솔루션과의 보완 관계

금융 정보망(ASAP) + 통화 탐지(통신사) + 단말 분리·시니어 UX(Sentinel-30) 영역 분담

기능	Sentinel-30	ASAP (금감원)	메타클라우드 (그놈목소리)	AIVOSS (국과수)	SKT 에이닷 (가족 케어)	KT 후후
통신사 미가입자 보호	YES	-	-	-	-	-
010 가상번호 단말 분리	YES	-	-	-	-	-
미끼봇 실시간 통화 흡수	YES	-	-	-	-	-
사기범 음성지문 DB	PART	-	YES	YES	PART	PART
멀티 에이전트 LLM 구조	YES	-	-	-	-	-
통화 중 실시간 STT 분석	PART	-	YES	-	YES	YES
금융사 정보 실시간 공유망	-	YES	-	-	-	-
가족 알림 (통화 중)	YES	-	-	-	YES	-
송금 거부권 (5분 룰)	YES	-	-	-	-	-
6법령 검토서 + 자문 전제	YES	-	-	-	-	-

➔ 기존 솔루션은 통신사 가입자·사후 분석 위주 — Sentinel-30은 미가입자·통화 시점·송금 거부권 영역 보완.

문제 재정의 — 사기 산업 ROI 분해


탐지·차단을 보완하여 사기범의 시간·정보·도구를 비용으로 전환하는 능동방어 메커니즘

Scam Industry ROI

산업 ROI 분해 — 3개 공격 벡터

Revenue

$$= [\text{발신 통화 수}] \times [\text{성공률}] \times [\text{건당 피해액}] - [\text{운영 비용}]$$




→ 공격 벡터 3종 — 통화 수↓ · 성공률↓ · 운영 비용↑ — 모두 동시에 작동시킨다.

30분 환수 골든타임

송금 완료(T+15)에서 인출 시작(T+30) 사이 — 미끼봇·정보 수집·자동 신고가 병렬 작동

30분 골든타임

송금 완료 ~ 인출 시작 사이의 시간 자산화



➔ T+15 ~ T+30 구간 — 환수 가능한 단 하나의 시간 창에 모든 자동화를 투입한다.

능동방어 7대 레이어

Defense-in-Depth 구조 — 한 레이어 우회 시 나머지 6개가 자원 흡수를 지속

7-Layer Defense-in-Depth

Sentinel-30의 능동방어 7대 레이어



→ AI 미끼봇 + 정보 수집 엔진 + 정보전 허브 + AI 보안 + IR + 법적 안전지대 + 시니어 UX.

시스템 데이터 흐름 (5단)

미끼번호 풀 → AI 미끼봇 → 정보 수집 엔진 → 정보 허브 → 시니어 가디언 앱

System Architecture

사기범 발신부터 정보전 허브 자동 공급까지 5단 데이터 흐름



→ 사기범 발신을 자원으로 흡수, 정보를 자동 공급해 ROI 감소 유도

→ 사기범 통화는 들어오는 순간 데이터가 된다 — 통신사·경찰·금감원으로 자동 전달.

가상번호 기반 사용자 단말 분리

010 회선을 양로원·경로당 비상연락처에 자연 노출 → 사기범 표적 리스트에 자동 수집 (Daisy AI Mugs list seeding 사례 참조)

기존 honeypot · Daisy AI

방식	미끼번호로 잘못 거는 것 대기
사용자 단말	무관
데이터 품질	가짜 시나리오
피해자 보호	간접 (시간 약탈)
시스템 진화	정체
법적 근거	통신사 사내 운영 약관
실데이터	사기범 잘못 거는 빈도 의존


Sentinel-30 Guardian Live

방식	010 가상번호 도착 호 SIP에서 가로챈
사용자 단말	통화에 일절 참여 X (벨소리 X)
데이터 품질	실제 사기범·실제 타이밍
피해자 보호	직접 (실시간 통화 차단)
시스템 진화	사용자 늘수록 학습 데이터 ↑
법적 근거	통비법 §3 (당사자) · 가입 동의
실데이터	가입자 통화량에 정비례 확장

→ 노출 동의: 양로원·경로당 협약 + 시니어 잘못 거는 경우 5초 안내("이 번호는 사기 대응 전용") 자동 송출.

다중 에이전트 대규모 언어 모델(LLM) 구조

단일 LLM은 긴 통화에서 토큰 누적 → 응답 지연·환각(없는 정보 생성) — 역할별 5종 분리 + 대화 요약 모듈로 입력 항상 8K 이하 유지



→ $T_{resp} = 0.9 + 0.4 + 0.2 = 1.5s$ · Cost = Opus1+Sonnet3+Haiku1 vs Opus5 → -62%.

응답 1.5초 — 사기범이 눈치챌까?

음성 인식(STT)→대규모 언어 모델(LLM)→음성 합성(TTS) 파이프라인 지연은 본질적 한계 — 5가지 회피 전략으로 노년 페르소나의 자연 발화 범위 안에 포함

응답 지연 분해 — 우리 시스템 vs 노년 자연 응답 분포

우리 시스템

1.5s (스트리밍 적용 후 0.8s)

노년 자연 응답

0.6초(P50) ~ 3.6초(P95) — 한국 노년 대화 코퍼스

① 노년 페르소나 자연 지연

70대는 본래 응답이 느림 — 1.5초는 P50
안에 포함

→ 한국 노년 대화 코퍼스 P50=2.1s

② 스트리밍 추론

Anthropic API 첫 토큰 ~400ms — TTS
즉시 스트리밍

→ 사용자 인지 지연 600~800ms

③ 발화 중 병렬 처리

사기범 발화 중간부터 STT 시작 — 끝나기
전 분석 완료

→ 마지막 음성 끝 시점 응답 준비

④ 사전 응답 캐싱

시나리오 8종 × 빈도 응답 30종 사전 합성

→ 인사·확인·재질문은 즉각 응답

⑤ Filler 발화 전략

"어... 잠깐만요" 즉시 → 본 답변은 1초 뒤

→ 사기범 입장에서 자연스러움

→ 5전략 적용 시 체감 응답 0.6~1.5초 → 노년 자연 응답 P50 범위 안 — 사기범 인지 회피.

통화 길이와 무관하게 입력 8K 토큰 일정 설계

단일 대규모 언어 모델(LLM)의 4대 한계에 대해 역할별 5종 에이전트 분리 + 대화 요약 모듈(Memory Compactor)로 체계적 접근

단일 LLM의 4대 한계

30분~2h 통화에서 컨텍스트 누적 시 발생

1 응답 지연 폭증

입력 토큰 누적 → 200K 도달 시 응답 3초→8초

→ 통화 흐름 끊김

2 페르소나 붕괴

초반 발화와 후반 발화 일관성 깨짐

→ 사기범이 봇임을 즉시 인지

3 환각(Hallucination)

긴 컨텍스트에서 없는 정보 생성

→ 실존 제3자 정보 노출 위험

4 비용 폭증

매 턴 누적 입력 토큰 × Opus \$5/M 단가

→ 30분 통화 1건 5,000원+ 도달 가능

다중 에이전트 + Memory Compactor

토큰 일정성 설계 메커니즘

1 역할 분리 5종

Orchestrator·Persona·Memory·Extractor·Safety

→ 각 에이전트는 자기 역할 컨텍스트만

2 Memory Compactor

5턴마다 JSON 요약 (Haiku, 1.4초)

→ Orchestrator 입력 = [요약본+최근2턴] ≤ 8K

3 모델 티어링

Opus 1 + Sonnet 3 + Haiku 1

→ vs 단일 Opus 5: 비용 -62%

4 백그라운드 갱신

Memory 요약은 응답 흐름과 비동기

→ 응답 지연 상한 1.5초 보장

→ 검증된 디자인 패턴 (LangGraph·AutoGen·Constitutional AI 등) — 본 프로젝트는 통화 도메인에 특화 적용.

수법(텍스트)이 1차 식별 기준, 음성지문은 보조

사기범 음성 데이터는 시중에 거의 없지만 음성 인식(STT)으로 텍스트화되면 수법 패턴은 즉시 추출 가능

텍스트 수법 분석 (1차)

단일 통화에서 즉시 작동 — 학습 데이터 의존도 낮음

- 1** **시나리오 8종 분류**
검찰·은행·자녀·택배·대출·세무서·경찰·보안업체
→ 발화 어휘로 결정 — **confidence score**
- 2** **엔티티 추출 4종**
계좌번호·URL·악성앱·송금 요구액
→ 정규식 + LLM 보조 추출
- 3** **사회공학 패턴**
급박성·권위·금전 압박 점수화
→ LLM zero-shot novelty score
- 4** **신규 키워드 모니터링**
사전 외 고빈도 어휘 등장 시 알람
→ 신종 수법 실시간 감지

음성지문 (보조 — 누적 가치)

단일 통화 가치 X · 누적 데이터에서만 작동

- 1** **동일 사기범 재방문 추적**
화자 식별(Speaker Embedding) · 유사도 ≥ 0.85
→ 미끼번호 여러 번 방문 시
- 2** **조직 단위 식별**
여러 화자의 음성 패턴 클러스터링
→ 사기 콜센터 조직 추론
- 3** **학습 데이터 부재**
시중에 사기범 음성 없음 — AIVOSS만 보유
→ 정확도 측정은 후속
- 4** **4주 PoC 한계**
인프라 시연 + Qdrant 운영 검증만
→ 정확도 사업화 후 누적

→ 단일 통화에서 우선 작동하는 것은 텍스트 수법 — 음성지문은 누적 데이터 확보 후 보완 가치.

신종 수법·사기범의 AI 무장 대응

데이터에 없는 새 수법 + 사기범이 인공지능 챗봇으로 무장한 시나리오 — 실시간 감지·통화 도중 대응·주기 학습 3단

실시간 감지 4종

통화 중 새 수법 식별

- **신뢰도 점수**
8종 분류기 결과 < 0.6
- **새로움 점수(Novelty)**
기존 8종 평균 거리 ≥ 0.7
- **신규 키워드 감시**
사전 외 고빈도 어휘 (예: 양자컴퓨터 사기)
- **사회공학 패턴**
급박성·권위·금전 압박 자동 평가

통화 도중 대응 4종

사기범이 AI 봇 사용해도

- **페르소나 유지**
안전 검증(Safety Guard) 보수 모드
- **정보 수집 계속**
계좌·URL·핵심 어휘 추출
- **합성 음성 탐지**
사기범 측 음성 합성(TTS) 식별
- **인간 검토자 알림**
1% 샘플링 → 의심 시 100%

주기 학습 5단

주간 자동 개선

- **Unknown 통화 벡터화**
언어 모델 임베딩 + 군집화
- **외부 정보 자동 연동**
경찰청·금감원 보고서 자동 수집
- **운영자 1회 검토**
새 시나리오 명명 + 라벨링
- **분류기 미세 조정**
응답 템플릿 추가
- **월 1회 분류기 갱신**
분류 정확도 주기적 갱신

→ 신종 수법 환경에서도 정보 수집 유지 — 분류기는 주간 배치로 자동 업데이트.

초기 시제품(PoC) 1주차 실측 → 추정치 보정

현재 수치는 공개 벤치마크·산정식 기반 추정 — 1주차에 우리 환경에서 실측해 임계값·모델 선정 확정

항목	현재 추정치 (공개 기준)	1주차 검증 방법	실측 미달 시 대안
음성 인식(STT) 정확도	WER 7% (HuggingFace Whisper-Korean v3)	경찰청 사례집 30건 + 합성 20건 = 50건 라벨링	네이버 클로바 스피치 전환
음성 합성(TTS) 자연도	MOS 4.2 (SuperTonic v2 논문 보고치)	70대 5명 청취 5점 척도 평가	ElevenLabs + 발화 패턴 보완
응답 지연	1.5초 (Anthropic Opus 4 공개 P50 0.9s 가산)	Claude API 30턴 평균 측정 + 로그 캡처	경량 모델 비중 ↑로 단축
통화당 운영비	약 2,240원 (Opus \$15/M·Haiku \$1/M 공개 단가)	PoC 50건 실측 평균 + 모델 티어링 비율	대화 요약 모듈 압축률 조정
분류 신뢰도 임계값	0.6 (Unknown 분기 기준 — 보수적 추정)	100건 라벨로 정밀도-재현율 곡선 측정	임계값 0.5~0.7 범위 탐색
화자 식별 유사도	≥ 0.85 (Qdrant cosine 권장 임계)	동일 화자 50쌍 vs 다른 화자 50쌍 분포	0.80~0.90 범위 조정
새로움 점수(Novelty)	≥ 0.7 (LangChain RAG novelty 권장 임계)	기존 8종 벡터 vs 신규 패턴 cosine 거리	조기 분기 임계값 조정


➔ 모든 추정치는 1주차 실측 후 조정 — 측정 데이터·로그는 본선·후속 단계 검증 근거로 누적.

데이터에 없는 새 수법도 끊지 않고 학습한다

분류기 신뢰도 0.6 미만(=학습 안 된 수법) → Unknown 분기로 통화 유지 → 주간 1회 운영자 검토 → 분류기 자동 재배포

Fallback + Active Learning

예외 시나리오 처리와 자가 학습 루프



흐름: 1차 분류기 → Known은 전용 페르소나 응답 · Unknown은 일반 페르소나로 통화 유지하면서 통화 전체 녹취 → 주간 클러스터링 → 라벨링 → 9번째 시나리오로 등재 → 분류기 재배포

➔ "학습 안 된 사기"도 통화 끊지 않고 정보로 흡수 → 8종 → 12종 → 16종 자동 확장.

AI 위협 분류 표준(MITRE ATLAS) 적용

사기범이 우리 미끼봇을 역공격할 가능성을 사전 차단 — ATLAS는 AI 시스템 공격을 표준화한 국제 프레임워크(미국 MITRE 사 운영)

ATTACK — 예상 공격 시나리오

AML.T0043

ATLAS 코드 — 적대적 음성 샘플 공격

사기범이 우리 미끼봇 발화를 합성해
재학습 데이터를 오염시키는 공격

- TTS 합성으로 노년 화법 모사
- 배경 노이즈로 음성 인식 교란
- 사칭 어휘 변형 + 개인정보 질문

목표 한 문장 공격도 재학습 자산으로 전환

DEFENSE · 5-STAGE

L1

입력 정규화

음성 인식(STT) 노이즈 제거 + 합성 음성 탐지

공격 코드 T0043·T0048 대응

L2

텍스트 수법 분석 (1차)

8종 시나리오 분류 + 계좌·URL·악성앱 정보 추출

단일 통화에서 즉시 작동

L3

안전 검증(Safety Guard)

악의적 프롬프트·개인정보 노출 입출력 검증

LLM 보안 표준(OWASP) 01-06

L4

임계값 동적 조정

신뢰도 < 0.6 또는 새로움 ≥ 0.7 → Unknown 분기

인간 검토자 알림 (1%→100%)

L5

음성지문 + 재학습 (보조)

화자 식별은 재방문 추적용 + 주간 재학습

조직 단위 식별 누적 가치

→ 공격 1건 → 5단 방어 → 재학습 자산화 — ATLAS·OWASP LLM Top10이 운영에 그대로 박혀있다.

구현 범위 — PoC와 사업화 단계 분리

4주 PoC는 4개 항목으로 한정 · 통신사·은행 정식 연계는 사업화 단계 추후 계획

Implementation Scope

이번 해커톤 실구현 vs v2 사업화 로드맵

LIVE DEMO · 실제 구현 4종

01

AI 미끼봇

멀티에이전트 5종 + STT/TTS 파이프라인



02

정보 수집 엔진

음성지문 DB + 시나리오 8종 분류 + 엔티티 추출



03

사기 시나리오 자동 분류

8종 + Unknown fallback + Active Learning 루프



04

AI 자체 보안 계층

MITRE ATLAS AML.T0043/T0048 + OWASP LLM Top10



추후 계획 · 사업화 후



FDS 실연계

시중은행 PoC — 1차 타겟



통신사 미끼번호 풀

KT 후후-SKT 협력 — MoU 단계



경찰청 사이버수사대 연계

디지털성범죄대응팀 채널



다국어 사기범 응대

중국어·러시아어 (글로벌 거점)



AML 자금세탁 영역 확장

Hack-Back 아닌 정보전 확장

발표·기획서는 "오늘 동작하는 것"과 "내일 동작할 것"을 명확히 구분

➔ 실구현 4종(미끼봇·정보 수집·시나리오 분류·AI 보안) + 추후 계획(FDS·통신사 MoU·다국어 등).

PoC → MVP → 사업화 — 단계별 구현 범위

예선 PoC 6종 완수 + 본선 MVP 3종 추가 + 사업화 단계 4종 정식 연계 — 단계마다 명확한 산출물

예선 PoC 구현 범위

핵심 모듈 6종

- 멀티에이전트 LLM (Orchestrator+4)
- 시나리오 8종 분류기
- 엔티티 추출 (계좌·URL·이름)
- Safety Guard (OWASP LLM)
- 010 가상번호 라우팅 (모의 SIP)
- 30초 시연 영상

본선 MVP 확장 범위

추가 3종

- Active Learning 루프 정식 가동
- 음성지문 DB 누적·식별
- 70대 5명 사용자 인터뷰 결과 반영

사업화 단계 (v3)

정부·금융 연계 4종

- 은행 FDS 실연계
- 통신사 정식 MoU·미끼번호 풀 확장
- 경찰청 사이버수사대 채널
- AIVOSS(국과수) 협력

기획·법무 트랙

전 단계 공통

- 6법령 + AI 기본법 검토 문서
- MITRE ATLAS·OWASP 매핑
- 개인정보·통비법 가이드라인
- 운영 리스크 8종 대응 가이드라인

→ 예선 6종 → 본선 +3종 → 사업화 +4종 — 단계별 산출물이 명확하다.

운영 비용 추정과 데이터 합법성

30분 통화 1건 운영비 산정식 + 음성·시나리오 데이터 출처 5종 명시

30분 통화 1건 비용 추정

음성 인식(STT) 30분 Whisper-Korean 자체 호스팅 · 단어 오류율 7%	0원
대화 요약 모듈 (경량 모델 × 6회) Haiku 4.5 입력 \$1/출력 \$5 per 100만 토큰	약 90원
응답 조율 에이전트 (Opus × 30턴) Opus 4.7 입력 \$5/출력 \$25 per 100만 토큰	약 1,400원
페르소나·정보 추출 (Sonnet × 30회) Sonnet 4.6 병렬 처리	약 420원
음성 합성(TTS) 노년 페르소나 SuperTonic v2 (단말 무료) + ElevenLabs 백업	0~240원

통화 1건 총 **약 1,910~2,150원**

음성/시나리오 데이터 출처

- ① 사기 시나리오 학습
경찰청 보이스피싱 사례집 공개본 + 뉴스
- ② 노년 페르소나 학습
AIHub 한국어 노년 화법 공개 데이터셋
- ③ 음성지문 DB ★ 민감
생체정보 — 「생체정보 보호 안내서 2024.12」 준수
- ④ 미끼번호 통화 녹취
통화 당사자 지위 기반 (통비법 §3·§14)
- ⑤ 010 가상번호 회선
팀 보유 선불유심 / 모의 SIP 라우팅으로 PoC

외부 사기범 음성 무단 수집 없음 · 가명처리 90일 파기 원칙

➔ TTS 후보 3종(SuperTonic·ElevenLabs·ClovaVoice) PoC 비교 후 1종 선정 — 70대 인터뷰에 자연도 평가 항목 포함.

팀 구성과 주차별 산출물

6인 학생팀 — 법리·보안 트랙 1명 전담 · 4주에 모듈 7개 통합

팀 EFFORT 배분 (6인)

기획·발표 리더 기획서·시연 영상 총괄	1명
ML / 봇 개발 Orchestrator·Persona·Extractor	2명
백엔드 / 통합 STT·Classifier·Reporter API	1명
UX / 가디언 앱 RN 앱·와이어프레임·푸시	1명
법리·보안 트랙 6법령 검토·OWASP·ATLAS	1명

주차별 산출물

- W1 기반 모듈 + 1주차 실측**
STT·Classifier·법리 검토 셋업
경찰청 사례집 30건 라벨링
- W2 에이전트 통합**
Orchestrator + Persona + Memory
Multi-agent 단일 통화 처리
- W3 정보 추출 + 신고 자동화**
Extractor·Reporter 모듈
통신사·경찰 모의 호출 로그
- W4 가디언 앱 + 시연 영상**
React Native 앱 + 자녀 푸시
30초 시연 영상 편집


→ 6인 학생팀 · 4주에 모듈 7개 통합 → 단일 통화 end-to-end 처리.

타겟 사용자 페르소나

고령 사용자 본인 · 은행 디지털보안 담당 · 보호자 자녀 — 통화 흡수 전·중·후 관점

Core Personas

타겟 사용자 3종 — 통화 흡수 전·중·후 관점



"검찰이라고 하니까 너무 무서웠다 — 자녀에게 연락할 정신이 없었다."
경찰청 보이스피싱 예방 사례집 (공개)

"FDS 롤 갱신은 사후적 — 새 수법은 며칠씩 늦는다."
금감원 디지털금융 보안 보고서 (공개)

"어머니 송금 직전 알았다면 통화를 끊을 수 있었다."
시민단체 피해자 조사 (공개)

➔ 1차 타겟은 60대+ 고령자와 그 자녀 — 공개 사례 인용 3건으로 페르소나 검증.

시니어 가디언 앱 — 2개 화면이 동시에 작동

고령자 화면(A): 위험 통화 자동 차단됨 알림 · 자녀 화면(B): 부모 위험 통화 실시간 감지 + 송금 거부권 5분 룰 발동



원칙: 한 화면 한 행동 · 28pt 이상 · 음성 안내 동시 · FCM+SMS 이중화 푸시 5초 이내 도달

A · 고령자 (72세 박OO)

위험 차단 알림 + "지금 통화 끊기" + 자녀 자동 알림

B · 자녀 (45세 이OO)

위험도 98% 표시 + 4선택지(송금 차단·3자 합류·통화 종료·신고 접수)

→ 고령자 1행동 + 자녀 4선택지 + 위험도 로그가 한 흐름으로 동시 작동.

PoC 시연 6단계와 화면 구성

녹음 입력 → 미끼봇 응대 → 정보 추출 → 신고 시뮬 → 가족 알림 — 3분할 화면으로 동시 가시화

시연 6단계 (예선 PoC)


- T+00:00 녹음 통화 입력**
사기범 검찰사칭 30초 녹음
- T+00:05 010 가상번호 수신**
팀 보유 회선 + 모의 SIP
- T+00:15 미끼봇 응대 시작**
Persona/Orchestrator 협업
- T+02:00 정보 추출 1차**
계좌·URL·시나리오 추출
- T+10:00 신고 자동 전송**
통신사·경찰·금감원 모의 호출
- T+15:00 가족 알림·거부권**
자녀 앱 푸시 + 5분 룰 시작

Live Demo Layout

본선 라이브 시연 화면 — 3분할 동시 가시화

LEFT · 사기범 입력 음성

(녹음 파일 재생)



검찰입니다.
김지수 씨 통장이...

(시연용 더미 대본)

PLAY 00:42 / 02:15

CENTER · 멀티 에이전트 동작

(처리 중인 에이전트가 발광)

Orchestrator
[Opus] 분기 결정 중

Persona
[Sonnet] 응답 생성

Memory
[Sonnet] T+38 압축 완료

Extractor
[Sonnet] 계좌 추출 시도

Safety
[Haiku] OK

RIGHT · 실시간 추출 결과

(히브로 전송되는 데이터)

시나리오	검찰 사칭	98%
음성지문	VP-3a8f...	신규
계좌	농협 301-XX	검출
URL	—	
약성명	—	
발신번호	+82-10-XXXX	변조 의심
통화시간	00:42 → 진행	

사기범 음성 → 멀티에이전트 동작 → 추출 결과 동시 가시화

→ 라이브 시연 불가 시 백업 영상 별도 — 3분할 화면(입력 음성·에이전트 동작·추출 결과)으로 한눈에 가시화.

법적 검토 및 안전장치

방어 유형 4분류 + 6법령 + AI 기본법 §50 + 형사소송법 §308-2 — 공개 법령·판례·정부 안내서 기반 자체 검토

Passive Defense

방화벽·탐지

일반 허용

Deceptive Defense

기만·허니팟

조건부 · 본 범위

Active Reconnaissance

정찰

고위험 회색지대

Hack-Back

역공격

배제 영역

- ① 통화 일방 녹음 — 대법원 2002도123 외 다수: 감청 미해당 (단 AI 봇 유추는 학계 비판)
- ② 음성지문 = 민감 생체정보 — 개인정보보호위원회 「생체정보 보호 안내서 2024.12」 준수
- ③ 수사기관 제공 — 형사소송법 §308-2(위법수집증거 배제) 회피 위해 합법 절차로 수집
- ④ AI 기본법 §31(고영향 AI)·§50(생성형 AI 표시) — 음성 워터마크 + 통화 후 AI 사용 자동 고지


➔ 6법령 + 정부 가이드라인 3종 직접 인용 — 본 슬라이드 자체가 법적 검토 기록으로 기능.

성과 지표 4종

PoC 데이터셋 기준 목표치 — 탐지율 · 시간 흡수 · 환수 골든타임 · 법정 신고시한 (SMART 검증)

KPI Dashboard

기존 솔루션 대비 Sentinel-30 핵심 4대 지표



모든 KPI는 SMART (Specific · Measurable · Achievable · Relevant · Time-bound) 충족


→ 탐지율 78→87% · 시간 약탈 0→30분 · 골든타임 240→30분 · 법정 신고 65→100%.

운영 리스크 8종 매트릭스

발생확률 × 영향도 우선순위 매핑 — 발화 가드레일·정보 차단·90일 파기·이의신청 등 대응 8축

Risk Matrix

발생확률 × 영향도 (우선순위 히트맵)



RISK LIST


- | | |
|--------------------------|------------------------------|
| R1 미끼봇 협박·모욕 발화 | R2 실존 제3자 정보 노출 |
| R3 사기범 데이터 무기한 보관 | R4 음성지문 오인식 (선익의 일반인) |
| R5 통신사 약관·전기통신사업법 | R6 AI 인간 사칭 (AI 기본법) |
| R7 적대적 공격 분류 우회 | R8 가디언 앱 개인정보 유출 |

→ 발견 → 대응 방안 8건 모두 사전 매핑 — 운영 단계에서 새로 발견될 회색지대가 적다.

사회적 효과 추정 (증분 모델)

통신사기피해환급법(2024.8.28) 시행 후 피해 -22~35% 진행 — 본 솔루션은 증분 효과로 가산

환급법 시행 효과 위에 누적되는 Sentinel-30 증분 효과



환급법 시행 효과(파랑) 위에 Sentinel-30 증분 효과(주황)가 누적되는 구조

→ 차별화 산출물 5종 — 법적 안전지대 · ATLAS · 멀티에이전트 · Active Learning · 시니어 UX.

기존 솔루션이 비운 5개 자리

메타클라우드·AIVOSS·통신사 4사·SKT 가족 케어 모두 있는 시장에서 우리만의 5개 자리

01

미가입자 보호

Daisy·통신사: 가입 필수

010 가상번호로 누구나

02

송금 거부권 5분

Daisy·SKT: 알림만

자녀 원격 차단 권한

03

시니어 통합 UX

Daisy: UI 없음 / SKT 부분

70대 인터뷰 기반 UX

04

6법령 검토서

Daisy: 영국 / SKT: B2B

한국 6법령 + §308-2 자체

05

한국 규제 부합

Daisy: Ofcom / SKT: 내부

AI 기본법·통비법 재설계

→ Daisy는 영국 통신사 사내 사례 — 우리는 한국 금융·법·고령자 컨텍스트 위에 다시 설계했다.

단계별 발전 계획 (v1 → v4)

예선 시제품(PoC) → 본선·최소 기능 제품(MVP) → 정부 지원 창업 또는 조달 진입 → 정식 납품

이번 (4주)

예선 시제품 완성

- 다중 에이전트 미끼봇
- 시나리오 8종 + 텍스트 패턴
- 법적 검토 기록
- 시연 영상

v2 (3~6개월)

본선·제품 완성

- 본선 라이브 데모
- 시제품 → 최소 기능 제품 안정화
- B2C 가족 케어 구독 베타 (월 3,000원)
- 공모전·창업 트랙 진입

v3 (6~12개월)

B2C 구독 + 정부 R&D

- 가족 구독 정식 출시 (목표 1만 가구)
- 창업진흥원·과기정통부 R&D 신청
- 정부 조달 입찰 등록 (나라장터)
- AIVOSS(국과수) 직접 제안

v4 (1년+)

정식 납품·확장

- B2C: 5~10만 가구 (연 매출 18~36억)
- B2G: 정부 R&D 또는 조달 입찰
- 성과 기반 후속 과제 확장

➔ B2C 가족 구독(월 3,000원) + B2G 정부 R&D·조달 — 듀얼 매출 트랙으로 사업화.

산출물 3개 — 앱 + 웹 + 백엔드

시니어 가디언 앱(React Native iOS/Android) · 운영자 대시보드(Next.js Web) · 미끼봇 서비스(Python FastAPI + LangGraph + Claude)

① 시니어 가디언 앱

모바일 — React Native

사용자: 자녀(보호자)

홈

부모 1인당 카드 · 위험도·최근 통화 상태

위험 감지

위험도 98% 표시 + 4선택지

거부권 5분

송금 차단 / 3자 합류 / 통화 종료 / 신고

통화 요약

Memory Compactor 출력 요약문

부모 설정

FCM·SMS 이중 푸시 · 28pt+ UX

결제

월 3,000원 가족 구독

② 운영자 대시보드

웹 — Next.js + Tailwind

사용자: 경찰·금감원·관제센터

실시간 모니터

활성 통화 N건 · 위험도 분포

Unknown 큐

신뢰도 <0.6 통화 라벨링 대기

라벨링 UI

운영자 검토 + 시나리오 명명

분류기 배포

주 1회 재학습 결과 승인 버튼

신고 로그

통신사·경찰망 전송 이력 검색

③ 미끼봇 서비스

백엔드 — Python FastAPI

사용자: 사기범 (가상번호로 통화)

STT

Whisper-Korean v3 (스트리밍)

Classifier

Sentence-Transformer (8종 분류)

Orchestrator

Claude Opus 4 (LangGraph 상태기계)

Persona+TTS

Sonnet 4 + SuperTonic v2 (스트리밍)

Extractor

Sonnet 4 + regex (JSON 출력)

Reporter

FastAPI + 모의 SIP 라우팅

DB

Qdrant + PostgreSQL + Redis

→ 사기범 통화 → 백엔드 처리 → 자녀 앱 알림 → 운영자 콘솔 라벨링 — 3개 산출물이 단일 흐름으로 연결.

보이스피싱 대응의 다음 단계. 법적 안전장치 안에서.

Active Defense는 윤리·법적 회색지대로 자주 오해받습니다.

우리는 침입·역공격을 배제하고, 당사자 통화 · 최소 수집 ·

명시 동의 · 수사기관 제공 경로를 분리해 리스크를 낮추는 구조로 설계했습니다.

차별화

능동방어 모델

탐지·차단을 보완해 사기범 자원을 비용으로 전환
Daisy AI 한국형 재설계

측정 가능

SMART KPI 4종 + 6법령 검토

PoC 탐지율 87% · 시간 흡수 30분 · 신고시한 100%
통비법 \$3 · AI 기본법 \$50 준수

단계적 확장

PoC → MVP → 정부 지원 → 납품

정부 R&D 지원 또는 조달 진입 (나라장터)
B2G 트랙으로 현실적 사업화