

Sentinel-30

보이스피싱 사기범의 ROI를 30분 안에 무너뜨리는 AI 능동방어 플랫폼

탐지·차단을 넘어 사기범의 시간, 음성지문, 계좌·URL을 증거 자산으로 전환한다.

RESEARCH QUESTION

사기 산업의 시간당 수익률을
어떻게 0에 가깝게 만들 것인가?

Golden Time · Guardian Live · Multi-Agent LLM

30분

환수 골든타임
송금완료~인출시작

8,545억

2024 피해액
경찰청, 전년 1.9배 증가

52.3%

60대 이상 피해
고령층 집중

7

Defense-in-Depth
능동방어 7대 레이어

■ PROBLEM · 사회적 압박 최고치

보이스피싱은 멈추지 않는다

기존 솔루션은 모두 '방어'에만 집중 — 사기범이 치를 비용은 사실상 0

8,545억

2024 피해액 (원)

경찰청 · 전년 1.9배 증가

52.3%

60대 이상 피해 비중

고령층 집중 피해

25%

피해 환수율 (미만)

금감원 2024

21,000

연간 발생 건수

건당 평균 4,100만원

→ 사기범이 잃을 자원이 없으므로 사기 산업은 멈추지 않는다.

사기 산업의 ROI를 0으로


탐지·차단을 넘어 사기범의 시간·정보·도구를 비용으로 전환한다

Scam Industry ROI

산업 ROI 파괴 메커니즘 — 3개 공격 벡터

Revenue

$$= [\text{발신 통화 수}] \times [\text{성공률}] \times [\text{건당 피해액}] - [\text{운영 비용}]$$



→ 공격 벡터 3종 — 통화 수↓ · 성공률↓ · 운영 비용↑ — 모두 동시에 작동시킨다.


■ TIMING · 30분 골든타임

송금 완료부터 인출까지 15분

이 구간에 미끼봇 시간 약탈·정보 허브 수집·통신사 차단·경찰망 자동 신고가 병렬 작동

30분 골든타임

송금 완료 ~ 인출 시작 사이의 시간 자산화



→ T+15 ~ T+30 구간 — 환수 가능한 단 하나의 시간 창에 모든 자동화를 투입한다.

능동방어 7대 레이어

한 레이어가 뚫려도 나머지 6개가 사기범 자원을 약탈한다

7-Layer Defense-in-Depth

Sentinel-30의 능동방어 7대 레이어




→ AI 미끼봇 + 정보 수집 엔진 + 정보전 허브 + AI 보안 + IR + 법적 안전지대 + 시니어 UX.

발신부터 정보전 허브까지 5단

사기범 발신을 자원으로 흡수, 정보를 자동 공급하여 ROI를 붕괴시킨다

System Architecture

사기범 발신부터 정보전 허브 자동 공급까지 5단 데이터 흐름




→ 사기범 발신을 자원으로 흡수, 정보를 자동 공급하여 ROI 붕괴

→ 사기범 통화는 들어오는 순간 데이터가 된다 — 통신사·경찰·금감원으로 자동 전달.

통화 2시간에도 컨텍스트 한계 없음

Memory Compactor가 5턴마다 요약 → Orchestrator 입력 항상 ≤ 8K 토큰



≤ 1.5초
응답 지연 상한


-62%
토큰 비용

∞
통화 길이 무제한

→ $T_{resp} = 0.9 + 0.4 + 0.2 = 1.5s$ · Cost = Opus1+Sonnet3+Haiku1 vs Opus5 → -62%.

학습 안 된 사기도 잡는다

신뢰도 0.6 미만 → Unknown 분기, 일반 노인 페르소나로 정보는 계속 수집



→ 주간 배치로 Unknown을 클러스터링·라벨링 → 분류 정확도가 매주 자동 개선된다.

이름값이 아닌 동작 가능한 위협 모델

AML.T0043 적대적 음성 샘플 1건 — 공격 → 5단 방어 흐름

ATTACK

AML.T0043

Adversarial Voice Sample

- TTS 합성으로 노년 화법 모사
- 배경 노이즈로 STT 교란
- 사칭 어휘 변형 + PII 질문

목표 한 문장 공격도 재학습 자산으로 전환

DEFENSE · 5-STAGE

L1

입력 정규화

주파수 대역 정규화 + 노이즈 제거 전처리

AML.T0048 대응

L2

Speaker Embedding 검증

음성지문 DB 매칭 (Qdrant cosine ≥ 0.85)

사기범 재방문 즉시 식별

L3

Safety Guard (Haiku)

Prompt Injection / PII Disclosure 입출력 검증

OWASP LLM01 · LLM06

L4

임계값 동적 조정

신뢰도 0.6 미만 → Unknown_Scam 분기 (정보 수집 유지)

Active Learning 루프 진입

L5

적대적 학습 재배포

주간 배치로 신규 공격 패턴 분류기 재학습

분류 정확도 매주 자동 개선

→ 공격 1건 → 5단 방어 → 재학습 자산화 — ATLAS·OWASP LLM Top10이 운영에 그대로 박혀있다.

사용자 폰을 통화에서 분리한다

보호번호(050/070)로 도착한 호를 AI가 먼저 받음 — 단말에는 벨소리조차 안 울림

기존 honeypot · Daisy AI

방식	미끼번호로 잘못 거는 것 대기
사용자 단말	무관
데이터 품질	가짜 시나리오
피해자 보호	간접 (시간 약탈)
시스템 진화	정체
법적 근거	통신사 사내 운영 약관
실데이터	사기범 잘못 거는 빈도 의존

Sentinel-30 Guardian Live

방식	보호번호 도착 호 SIP에서 가로챈
사용자 단말	통화에 일절 참여 X (벨소리 X)
데이터 품질	실제 사기범·실제 타이밍
피해자 보호	직접 (실시간 통화 차단)
시스템 진화	사용자 늘수록 학습 데이터 ↑
법적 근거	통비법 §3 (당사자) · 050 가입 동의
실데이터	가입자 통화량에 정비례 확장

➔ 예선 PoC: 녹음/실시간 입력 → 모의 SIP → 사기점수 → 가족 알림 UI 까지 시연 가능.

한 화면, 한 행동


70대 5명 정성 인터뷰 기반 · 28pt 이상 큰 글씨 · 음성 안내 동시 · 5초 내 자녀 푸시

Senior Guardian — Wireframe

A · 고령자 화면 (72세 박OO)

70대 5명 인터뷰 기반 · 한 화면 한 행동 원칙

B · 자녀 화면 (45세 이OO)



원칙: 한 화면 한 행동 · 28pt 이상 · 음성 안내 동시 · FCM+SMS 이중화 푸시 5초 이내 도달

➔ 본선 데모: 고령자 1행동 + 자녀 4선택지 + 위험도 로그를 한 흐름으로 시연한다.

벤치마크는 영국, 설계는 한국

영국 O2 Daisy AI가 못 한 5가지를 한국 금융·법 워크플로 위에 재설계

01

Guardian Live

사용자 폰을 통화에서 분리

보호번호 SIP 가로채기 —
Daisy는 미끼번호 대기형

02

멀티 에이전트 LLM

통화 2h에도 컨텍스트 무한

Memory Compactor —
Daisy는 단일 LLM 토큰 한계

03

금융 IR 워크플로

금감원 24h 자동 신고

전자금융감독규정 §31~38 —
한국 규제 직접 부합

04

법적 안전지대

6법령 리스크 매트릭스

Deceptive Defense 분류 +
AI기본법 §50 대응

05

시니어 가디언 UX

70대 인터뷰 5명 검증

가족 거부권·송금 차단 — Daisy는
사용자 UI 없음

→ Daisy는 영국 통신사 사내 사례 — 우리는 한국 금융·법·고령자 컨텍스트 위에 다시 설계했다.

경쟁사가 비운 능동 약탈 영역

탐지·차단 솔루션은 빨강 표시 칸을 못 채운다 — Sentinel-30만 모든 칸을 채운다

기능	Sentinel-30	KT 후후	SKT 에이닷	토스 사이렌	시티즌코난	더치트
사기범 시간 약탈 (미끼봇)	YES	-	-	-	-	-
사기범 음성지문 DB	YES	-	-	-	-	-
멀티 에이전트 LLM	YES	-	-	-	-	-
금감원 24h 자동 신고	YES	-	-	-	-	-
가족 알림 + 송금 거부권	YES	-	PART	-	-	-
6개 법령 리스크 검토서	YES	-	-	-	-	-
MITRE ATLAS 위협 모델	YES	-	-	-	-	-

→ 경쟁사 모두 탐지·차단에 머무는 동안, Sentinel-30은 유일하게 사기범 자원을 능동 약탈한다.


■ KPI · 성과 지표 4종

측정 가능한 결과만 약속한다

탐지율 · 시간 약탈 · 환수 골든타임 · 법정 신고시한 — 4축 모두 SMART 검증

KPI Dashboard

기존 솔루션 대비 Sentinel-30 핵심 4대 지표



모든 KPI는 SMART (Specific · Measurable · Achievable · Relevant · Time-bound) 충족

→ 탐지율 78→87% · 시간 약탈 0→30분 · 골든타임 240→30분 · 법정 신고 65→100%.

사기범을 망치되, 법의 경계 안에서

Hack-Back 배제 · 통화 당사자 지위 · 최소 수집 · 수사기관 제공 경로 분리

Passive Defense

방화벽·탐지

일반 허용

Deceptive Defense

기만·허니팟

조건부 · 본 범위

Active Reconnaissance

정찰

고위험 회색지대

Hack-Back

역공격

배제 영역

대법원 2008도1237 — 통화 당사자 일방 녹음 합법 (AI 봇 적용은 판례 유추)

AI 기본법 부칙 §2 1년 계도기간(2027.1.21까지) 활용 + 규제 샌드박스·법무 의견서로 보강

→ 6법령(통비법·개인정보법·신용정보법·정보통신망법·형법·AI기본법) 매트릭스 §8.2에 별도 기재.


■ RISK MATRIX · 발생확률 × 영향도

8대 리스크를 미리 그려둔다

미끼봇 발화 가드레일·실존 정보 차단·90일 파기·MoU·계도기간·이의신청 8축으로 방어

Risk Matrix

발생확률 × 영향도 (우선순위 히트맵)



R1 미끼봇 협박·모욕 발화

R2 실존 제3자 정보 노출

R3 사기범 데이터 무기한 보관

R4 음성지문 오인식 (선의의 일반인)

R5 통신사 악관·전기통신사업법

R6 AI 인간 사칭 (AI 기본법)

R7 적대적 공격 분류 우회

R8 가디언 앱 개인정보 유출

→ 발견 → 대응 방안 8건 모두 사전 매핑 — 운영 단계에서 새로 발견될 회색지대가 적다.

오늘 동작하는 것 vs 내일 동작할 것

발표·기획서는 이 둘을 절대 섞지 않는다

Implementation Scope

이번 해커톤 실구현 vs v2 사업화 로드맵

LIVE DEMO · 실제 구현 4종

01

AI 미끼봇

멀티에이전트 5종 + STT/TTS 파이프라인



02

정보 수집 엔진

음성지문 DB + 시나리오 8종 분류 + 엔티티 추출



03

사기 시나리오 자동 분류

8종 + Unknown fallback + Active Learning 루프



04

AI 자체 보안 계층

MITRE ATLAS AML.T0043/T0048 + OWASP LLM Top10



v2 ROADMAP · 사업화 후



FDS 실연계

시중은행 PoC — 1차 타겟



통신사 미끼번호 풀

KT 후후-SKT 협력 — MoU 단계



경찰청 사이버수사대 연계

디지털성범죄대응팀 채널



다국어 사기범 응대

중국어·러시아어 (글로벌 거점)



AML 자금세탁 영역 확장

Hack-Back 아닌 정보전 확장

발표·기획서는 "오늘 동작하는 것"과 "내일 동작할 것"을 명확히 구분

→ 실구현 4종(미끼봇·정보 수집·시나리오 분류·AI 보안) + v2 로드맵 5종(FDS·MoU·다국어 등).

■ TEAM & BUDGET · 6인 · 130만원 · 4주

법리·보안 트랙 1명이 차별화 자원

다른 팀에 없는 전담 트랙 — 6법령 검토서·IR 플레이북·MITRE ATLAS 모두 한 명이 책임

팀 EFFORT 배분 (6인)

기획·발표 리더	1명	15%
ML / 봇 개발	2명	35%
백엔드 / 통합	1명	15%
UX / 시연 영상	1명	15%
법리·보안 트랙	1명	20%

예산 4주 예산

LLM API 호출	400,000원
TTS 음성 합성	150,000원
70대 인터뷰 사례비 (5명)	250,000원
시연 영상 편집	200,000원
클라우드 인프라	200,000원
기타 (라이선스·소품)	100,000원

합계

약 130만원

➔ 학생팀 130만원 + 4주 — 풀스택 구현은 어렵지만 차별화 자원 1명을 확보했다.

■ IMPACT · 사회적 효과 (보수적 추정)

도입 1년차에 약 1,280억 절감

보이스피싱 피해액 -15% · 고령층 피해 -40% · 환수 골든타임 240→30분 · 사기범 ROI 0

-15%

보이스피싱 피해액

8,545억 → 7,265억

약 1,280억 절감

-40%

60대 이상 피해 비중

52.3% → 31.4%

가족 거부권 효과

30분

환수 골든타임

240분 → 30분

허브 자동 트리거

0

사기범 시간당 매출

산정 불가 → 0 수렴

30분~2h 시간 약탈

→ 차별화 산출물 5종 — 법적 안전지대 · ATLAS · 멀티에이전트 · Active Learning · 시니어 UX.

예선 PoC → 본선 데모 → 사업화

각 단계별 심사 포인트와 사업화 경로를 명확히 분리

이번 (4주)

예선 PoC

- 멀티에이전트 미끼봇
- 시나리오 8종+Unknown
- 음성지문 DB
- 법적 안전지대 설계서
- 30초 시연 영상

v2 (3~6개월)

본선 → 사업화

- 시중은행 FDS PoC
- 통신사 미끼번호 풀 MoU
- 경찰청 사이버수사대 채널
- Active Learning v2

v3 (6~12개월)

다국어·국제

- 중국어·러시아어 응대
- 글로벌 거점 정보 공유
- AML 자금세탁 영역 확장

v4 (1년+)

한국형 모델 수출

- 동남아·일본 진출
- Ofcom Daisy AI 역방향
- 글로벌 표준 제안

→ 예선은 학생팀 4주 — 본선·사업화에서 통신사·은행·수사기관과 정식 연계로 확장한다.

배점 기준에 맞춰 증거를 배치

AI 기술 활용 30점 영역에 가장 두텁게 — 멀티에이전트 + 음성지문 + ATLAS

25

points

문제 적합성

8,545억·60대 52.3%·환수율 25% 정량 근거 + 30분 골든타임 재정의

p.2-4

30

points

AI 기술 활용

멀티에이전트 5종 · 음성지문 DB · 8종+Unknown · MITRE ATLAS / OWASP LLM

p.6-9

25

points

파급력·확장성

예선→본선→사업화 3단계 + 4축 타겟 (은행·금감원·통신사·수사기관) + 글로벌 v4

p.17,20

20

points

아이디어 혁신성

사기범 ROI 0 재정의 + Guardian Live 보호번호 모델 + 6법령 안전지대

p.3,10,12

→ 100점 만점 배점에 매핑된 증거를 22장 슬라이드 곳곳에 배치 — 심사 누락 0.

사기범을 망친다. 법의 경계 안에서.

Active Defense는 윤리·법적 회색지대로 자주 오해받습니다.

우리는 침입·역공격을 배제하고, 당사자 통화 · 최소 수집 ·

명시 동의 · 수사기관 제공 경로를 분리해 리스크를 낮추는 구조로 설계했습니다.

국내 유일

Active Defense 능동 약탈 모델

탐지·차단을 넘어 사기범 자원을 비용으로 전환
Daisy AI 한국형 재설계

실측 가능

SMART KPI 4종 + 6법령 검토

87% 탐지 · 30분 약탈 · 100% 신고시한
통비법 §3 · AI 기본법 §50 대응

확장 명확

예선 → 본선 → 사업화 → 수출

은행 FDS · 통신사 MoU · 경찰망 연계
글로벌 v4: 동남아·일본 진출